



UNIVERSITÄT LEIPZIG

Institut für Informatik
Fakultät für Mathematik und Informatik
Abteilung Datenbanken

Kolorieren Historischer Fotos der Stadt Leipzig

Bachelorarbeit

vorgelegt von:
Daniel Grohmann

Matrikelnummer:
3710183

Betreuer:
Prof. Dr. Erhard Rahm
Lucas Lange

© 2022

Dieses Werk einschließlich seiner Teile ist **urheberrechtlich geschützt**. Jede Verwertung außerhalb der engen Grenzen des Urheberrechtsgesetzes ist ohne Zustimmung des Autors unzulässig und strafbar. Das gilt insbesondere für Vervielfältigungen, Übersetzungen, Mikroverfilmungen sowie die Einspeicherung und Verarbeitung in elektronischen Systemen.

Inhaltsverzeichnis

Abbildungsverzeichnis	ii
1. Einleitung	1
1.1. Motivation	1
1.2. Ziele der Arbeit	2
1.3. Aufbau der Arbeit	2
2. Historie	3
2.1. Anfänge der Fotografie	3
2.2. Handkolorierung	5
2.3. Digitales Kolorieren	6
3. Grundlagen	7
3.1. Maschinelles Lernen	7
3.1.1. Lerntechniken	7
3.1.2. Künstliche Neuronale Netze	8
3.1.3. Tiefes Lernen	10
4. Verwandte Arbeiten	11
4.1. Neuronale Netze GAN's: Fokus auf DeOldify	12
4.1.1. Deep Learning Techniken des Kolorierens	12
4.1.2. DeOldify	13
4.2. Implementierung	14
4.3. Evaluation (Vergleich Projekte)	15
4.4. Fazit und Ausblick	16
4.5. Literaturverzeichnis	17
Literatur	18
4.1. Anhang	20

Abbildungsverzeichnis

2.1. Blick aus dem Arbeitszimmer in Le Gras, 1826. NICÉPHORE NIÉPCE - HARRY RAN-	
SOM CENTER'S GERNSHEIM COLLECTION, THE UNIVERSITY OF TEXAS AT AUSTIN	3
3.1. McCulloch-Pitts-Neuron	9
3.2. Allgemeiner Aufbau eines vorwärtsgerichteten KNN-Modells	9

1. Einleitung

1.1. Motivation

(Copy Paste vom Exposé, wird noch geändert)

Das Färben alter Schwarz-Weiß-Fotos ist für viele, die sich damit beschäftigen, ein spaßiges Gim-mick, etwas zum Probieren oder wird zur Befriedigung der eigenen Neugier genutzt: Man fragt sich, wie das Elternhaus, welches über Jahrzehnte von Generation zu Generation weitervererbt wurde, ausgesehen haben kann. Oder - mit diesem verbunden - wie die Urgroßeltern in Farbe aussahen, um sie oder ihren Kleidungsstil mit dem der lebenden Familienmitglieder zu vergleichen. Außerdem versuchen professionelle Koloristen, überlieferte Kunstwerke und Fotos realistisch zu modernisieren und ihnen neues Leben einzuhauchen. Jedoch ist gerade die Realitätsnähe beim Kolorieren historischer Fotos eine - vielleicht die größte - Herausforderung. Es ist nie einhundert Prozent möglich zu sagen, dass diese Person oder dieses bestimmte Gebäude damals wirklich so aussah, es sei denn, es existiert ein farbiges Pendant. Deshalb ist der Ansporn der meisten fachkundigen Koloristen eher die Plausibilität. Es wird versucht, die Objekte auf den Fotos so darzustellen, wie sie womöglich ausgesehen haben könnten.

Doch mittlerweile sind die Zeiten, in denen man historische Fotos höchstaufwändig manuell Färben musste, durch den technologischen Fortschritt und kluge Köpfe wie Jason Antic, Emil Wallner (...) Geschichte. Durch die Entwicklung der letzten Jahre im Bereich des Maschinellen Lernens ist der Akt des Färbens durch Programme wie DeOldify, OpenCV, Picture Colorizer, AKVIS Coloriage und Photomyne so benutzernah und leicht zugänglich wie nie. So ist beispielsweise letzteres sogar als Applikation für Tablets und Smartphones erhältlich.

1.2. Ziele der Arbeit

1.3. Aufbau der Arbeit

2. Historie

2.1. Anfänge der Fotografie

Die Camera obscura, welche ursprünglich nur ein Raum mit einem lichtdurchlässigen Loch war, beschrieb den ersten Mechanismus, ein vom menschlichen Auge erkanntes Bild (zumindest temporär) zu projizieren. Erste Überlieferungen von Anwendungen dieses Mechanismus gibt es laut LEFÉVRE [LEF07] erst im 17. Jahrhundert, wobei vermutet wird, dass dieses Phänomen bereits in der Antike entdeckt wurde. Die ersten physischen Exemplare in verschiedenen Formen beinhalteten nur eine einzige konvexe Linse. Die Bilderzeugung erfolgte lediglich mithilfe von extern einströmendem Sonnenlicht, welches durch Brechung in der Linse ein reales, invertiertes Abbild auf einer dahinterliegenden Oberfläche erzeugte. Dieses konnte daraufhin von Künstlern in einem umständlichen Prozess des Rotierens und Wendens (analog zur Umkehrung eines Negativs mit einer aktuellen Kamera) abgepaust oder abgezeichnet werden. Neben der großen Wertschätzung für die Welt der Kunst war die Camera obscura in der Astronomie als Observationsmittel, in der Anatomie zum Verstehen des menschlichen Auges und in der Ergründung der wissenschaftlichen Optik von wesentlicher Bedeutung. [LEF07; MIL98]

Erst im Jahr 1826 gelang es, die flüchtigen Bilder in der Dunkelkammer zu fixieren und somit das erste "richtige" Foto herzustellen. Der Franzose Joseph Nicéphore Niépce gilt als der Erfinder des ersten Verfahrens, welches dauerhafte Bilder erzeugen konnte, der sogenannten Heliografie. Ihm gelang es, mithilfe von einer dünnen Asphaltschicht, welche in Lavandelöl gelöst und anschließend auf einer versilberten Kupfer- oder Zinnplatte angebracht wurde, den Blick aus seinem Arbeitszimmer als Fotografie bei einer Belichtungszeit von ungefähr acht Stunden zu entwickeln. Diese erste Art der Momenterfassung gilt als die älteste erhaltene Fotografie (Abb. 2.1). Gemäß EDER [EDE84] war Niépces größte Herausforderung nun, seine bahnbrechende Entdeckung anwendungsreif und für eine breitere Masse zugänglich zu machen. Deshalb schloss er sich 1829 mit dem französischen Maler Louis Daguerre zusammen, jedoch gelang es den beiden während Niépces Lebenszeiten nicht, das anfangs sehr materiell aufwändige Verfahren kommerziell nutzbar zu machen. [EDE84]


Erst 1839 gelang es Daguerre, monochrome (schwarz-weiße) Fotos reproduktiv anfertigen zu können. Aufbauend auf den Grundlagen Niépces entdeckte er, dass das Silberiodid allein, was beim Behandeln der versilberten Kupferplatten mit Ioddampf entsteht, durch seine Lichtempfindlichkeit reicht, um Bilder herzustellen. Eine Alternative stellte Quecksilberdampf dar und sorgte für



Abb. 2.1.: Blick aus dem Arbeitszimmer in Le Gras, 1826.
NICÉPHORE NIÉPCE - HARRY RANSOM CENTER'S GERNSHEIM COLLECTION, THE UNIVERSITY OF TEXAS AT AUSTIN

ein ähnliches Ergebnis. Für seine sogenannte Daguerreotypie verwendete er eine verbesserte und kleinere Version der Camera obscura (oder Lochkamera) als Fotoapparat. [BW00]

Die Daguerreotypie wurde durch darauf aufbauende Methoden wie die Kalotypie, Ambrotypie und Tintypie, welche erste Versuche der Farbfotografie repräsentierten, ergänzt und verfeinert [LAV+09]. Jedoch blieb die Mehrheit der fotografischen Aufnahmen bis zur Mitte des 20. Jahrhunderts monochrom [HAC12].



(WorkInProgress)

2.2. Handkolorierung

Im Allgemeinen wird das Kolorieren als das Färben monochromer (schwarz-weißer) Bilder, seien sie bewegt oder unbewegt, definiert [LUA+07]. Im Englischen wird der Begriff "colorization" auch vom Begriff "coloring" (oft mit "hand coloring" spezifiziert) unterschieden. Ersterer beschreibt meist dabei den digitalen Vorgang, letzterer ist älter und an den händischen Prozess angelehnt. In der deutschen Sprache wird diese Differenzierung nicht vorgenommen. Neben der mittelalterlichen Buchmalerei, die den Ursprung der händischen Illustrationsfärbung darstellt, soll in dieser Arbeit aber vor allem auf das Färben von Fotos eingegangen werden.

Die Handkolorierung von Fotos, wie wir sie heute kennen, wurde direkt nach der Entwicklung erster Daguerrotypen mit verschiedenen Ansätzen in Angriff genommen und ist somit erstmals auf diese Zeit zurückzuführen. Für eine Zusatzgebühr konnte man beim Künstler verlangen, dass das schwarz-weiße Foto nachkoloriert wird. Der Beauftragte notierte sich die Farbe der Kleidung, Augen und Haare des abgebildeten Kunden, falls es sich um ein Portrait handelte [HAN13]. Dieses Angebot der nachträglichen Einfärbung war notwendig, da laut HENISCH ET AL. [HH96] bei Weitem nicht alle Menschen von der "neuen Magie" der ersten monochromen Fotos überzeugt waren. Sie vermissten die Farbenfroheit der Gemälde, die in ihrem Zuhause hingen, und trachteten danach, ein Gegenmittel zur Monotonie der Abbildungen zu finden. Diese Bestrebungen nach mehr Realismus wurden zu Beginn mit einem Gemisch aus verschiedenen Pigmenten und Gummi Arabicum als Bindemittel erreicht. Unter Hitzeeinfluss wurden die Farbstoffe anschließend auf den Daguerrotypen fixiert. Johann Baptist Isenring war 1839 der erste Künstler, der diese Technik nutzte. [FER08; HH96]

Seit der Mitte des 19. Jahrhunderts ist mit den Methoden des frühen Kolorierens stetig weiterexperimentiert wurden, jedoch ohne nennenswerte Fortschritte zu erreichen. Erst einige Jahre später, mit der Erfindung der Solarkamera und damit einhergehend das Vorhandensein einer ausreichend starken Lichtquelle während des Vorgangs, konnten Fotos vergrößert auf Papier oder Leinwänden dargestellt werden [TOW73]. So konnten beispielsweise Portraits für das Bearbeiten leichter zugänglich gemacht und in Lebensgröße abgebildet werden. Das durch diese und weitere Errungenschaften vereinfachte Handkolorieren war bis zur Mitte des 20. Jahrhunderts und zur Erfindung des Kodachrome Farbfilms die beliebteste Methode, um gefärbte Fotografien herzustellen. Trotz der Existenz der seitdem deutlich unkomplizierteren Methode und deren Nachfolgern, war das händische Kolorieren von Fotos in den folgenden Jahren immer noch von großer Bedeutung und erlebte in den 1970ern eine Art Wiedergeburt, weil viele Menschen sich nach dem Antiken und Alten sehnten. Bis heute ist die Handkolorierung eine beliebte Tätigkeit, sei es wegen visueller Ästhetik oder der Beständigkeit der beim Vorgang verarbeiteten Farbpigmente. [II05]

2.3. Digitales Kolorieren

FERGUSON [FER08] behauptet, dass die gewaltigsten Hürden, die es zu bezwingen galt, neben den materiellen Kosten vor allem der körperliche und zeitliche Aufwand, monochromen Aufnahmen mit Farben einen neuen Glanz zu verleihen, waren. Das Foto musste erst mit den vorhandenen Praktiken geschossen, entwickelt und gedruckt werden, bevor das Ergebnis von einem - meist demselben - Künstler in einem oft langwierigen Prozess handgefärbt werden konnte. Die nachgefragtesten Fotografen und Koloristen besaßen deshalb eine traditionelle künstlerische Ausbildung. Kolorierte Fotos waren deutlich erschwinglicher als echte Gemälde und erwiesen sich in der Öffentlichkeit schnell als lukrativ. [FER08; HOP10]

Heutzutage ist das Kolorieren hauptsächlich ein rechnergestützter Prozess, wobei der Aufwand des Färbens praktisch komplett von Programmen und deren Algorithmen übernommen wird. Moderne Technologien und der Fortschritt im Bereich der künstlichen Intelligenz haben diesen revolutioniert und deutlich vereinfacht. Trotz alledem ist es noch lange kein trivialer Vorgang. Besonders wenn man ausgezeichnete Resultate erwartet, sind eine gewisse Expertise und Erfahrung, gerade wenn es um Fotorestaurierung geht, fundamental.

(wird fortgesetzt und verknüpft mit folgendem Chapter)

3. Grundlagen

3.1. Maschinelles Lernen

Maschinelles Lernen (ML) ist heutzutage aus vielen Bereichen der Informationstechnik nicht mehr wegzudenken. Die Anwendungsweite reicht von der Filterung von Inhalten in sozialen Netzwerken, über Verfeinerung von Web-Suchen bis hin zum Zuschneiden von Werbe- und Nachrichteneinblendungen des Nutzers. ML-Systeme werden desweiteren in der digitalen Spracherkennung, -verarbeitung und zur Analyse von Bildmaterial (beispielsweise in der medizinischen Diagnostik) eingesetzt. Bei letzterem spielt vor allem die Erkennung und Färbung spezifischer pathologischer (möglich krankhafter) Bestandteile wie Tumoren [Fak+13] und Myomen [Rot+15] eine große Rolle. [LBH15]

Im Allgemeinen ist Maschinelles Lernen ein Teilgebiet der Künstlichen Intelligenz (KI). Es sorgt dafür, dass Systeme mithilfe bestimmter Lernalgorithmen der KI gewisse Muster oder Regeln in meist großen Datenmengen erkennen, sie beschreiben, aus ihnen lernen und sogar Ergebnisse voraussagen können. ML ist dazu da, auch ohne explizites Programmieren komplexe Aufgaben (wie zum Beispiel das Färben monochromer Bilder) zu lösen. Dabei ist es wichtig, den geeigneten Algorithmus zu finden, damit ein gewünschtes Resultat erreicht werden kann. [DFO20]

Laut MOHAMMED ET AL. [MKB16] ist die fundamentalste Frage dieses Themengebiets, wie man Computer dazu bekommt, sich selbst (mit gesammelter Erfahrung und etwas Starthilfe von außen) zu programmieren. Deshalb ist ein weiterer wichtiger Punkt zur Bedeutung von ML-Programmen deren Adaptivität. Durch das ständige Trainieren mit angemessenen Datensätzen werden von den Programmen neue Lösungsstrategien erarbeitet und Resultate gefunden. Anders als konventionelle Computerprogramme, die einmal geschrieben nur schwer oder gar nicht veränderbar sind, sind sie durch das Anwenden der gelernten Erfahrungen deutlich flexibler und vor allem zu variierendem Input adaptiver. Um die genannten Ziele zu erreichen, werden beim Maschinelles Lernen verschiedene Techniken eingesetzt, die im Folgenden kurz vorgestellt werden. [MKB16; SB14; MM21]

3.1.1. Lerntechniken

Überwachtes Lernen

Überwachtes Lernen (engl. supervised learning) bedeutet, dass dem Programm neben der Eingabedatenmenge die gewünschten Ausgaben mitgegeben werden. Diese "gelabelten" oder beschrifteten Daten beinhalten dabei deren Attribute und Bedeutungen. Ziel dieses Vorgangs ist es, die Muster in den übergebenen Daten zu erkennen und ein Mapping von den übergebenen Eingaben zu den Ausgaben zu erstellen. Dies geschieht zum Beispiel bei der herkömmlichen Klassifizierung von Tierbildern, bei der die Programme mit jedem Input (Bild einer Katze) ein Output (Katze) assoziieren sollen, bei einem Hundebild soll ein Hund erkannt werden. Desweiteren soll nach Erstellen des Mappings neue Inputs mit bekannten Outputs verknüpft werden. Dieser Ablauf belegt letztendlich das Lernen des Programms, das größte Ziel der Arbeit mit (überwachten) Lernalgorithmen.

Nach einigen Vorgängen und wiederholtem Trainieren des Programms kann sogar sein Verhalten unter Verwendung neuer Datensätze vorausgesagt werden. Der Überwacher (oder supervisor) ist dabei meist ein Mensch, der die Daten labelt und zur Verfügung stellt. Jedoch können Maschinen auch Überwacher sein, was ressourcensparender aber oft (noch) ungenauer als das menschliche Pendant ist. Überwachtes Lernen ist deshalb laut GOODFELLOW ET AL. [Goo+20] zum einen durch die Abhängigkeit menschlichen Inputs und Kontrolle, zum anderen durch den noch unoptimierten Lernprozess der Programme eingeschränkt, der noch nicht mit dem des Menschen konkurrieren kann. Beispielsweise müssen die Programme oft mehrere Millionen Male an Datensätzen trainiert werden, um die menschliche Performance zu übertreffen, wobei der Mensch ausreichende Ergebnisse bei deutlich geringerem Trainingsaufwand liefert. Natürlich ist dabei die Erwartungshaltung an die trainierte KI und der gelegte Maßstab sehr hoch, um den größtmöglichen technischen Fortschritt zu erlangen und bestimmte Abläufe stets zu optimieren. [MKB16; Goo+20]

Neben der bereits erwähnten Klassifikationsalgorithmen werden häufig Regressionsalgorithmen beim überwachten Lernen eingesetzt.

Unüberwachtes Lernen

Beim unüberwachten Lernen (engl. unsupervised learning) fehlen sowohl Überwacher als auch die gewünschten Ausgaben, die erzeugt werden sollen. Dabei soll das Programm selbst die Struktur und Zusammengehörigkeit der Daten erschließen, ohne die Bedeutung zu kennen. Diese Technik wird vor allem beim Ermitteln neuer riesiger Informationsmengen im Bereich Big Data benutzt, um diese später eventuell zu labeln. Diese Technik wird unter anderem bei Algorithmen wie der Clusteranalyse angewendet, die im Marketing und in der Produktentwicklung zur Kundengruppierung eingesetzt wird, um beispielsweise Newsletter zu personalisieren [Sem22]. [MKB16]

(to be continued)

3.1.2. Künstliche Neuronale Netze

Die Basis für Künstliche neuronale Netze (engl. artificial neural networks, hier KNN) orientiert sich an der Physiologie des Menschen, genauer gesagt am Neuronennetzwerk des menschlichen Gehirns. Diese Neuronen, welche aus Axonen, Dendriten und Synapsen bestehen, kommunizieren mittels elektrischen Impulsen im neuronalen Geflecht untereinander [Kro08]. Das daran angelehnte Modell des künstlichen Neurons (Abb. 3.1) von MCCULLOCH und PITTS beschreibt, wie es eine gewichtete Summe (weighted sum) von n Eingangssignalen (I_j mit $j = 1, 2, \dots, n$) in einer Schwellenfunktion (threshold function) verarbeitet und Ausgaben liefert. Bei dieser sogenannten "binären Schwelleneinheit" wird 1 ausgegeben, wenn die Summe eine gewisse Schwelle erreicht und 0 sonst. Die Gewichtungskoeffizienten bestimmen die Relevanz der Neuronenkette im Netzwerk, also wie wichtig die Verbindung zweier oder mehrerer Neuronen für das neuronale Netz sind.




Abb. 3.1.: McCulloch-Pitts-Neuron

Die Eingangssignale kommen dabei von anderen Neuronen im Netzwerk und aus externen Quellen. Positive Signale wirken exzitatorisch (erregend) und negative inhibierend (hemmend) auf das System. Die Auswertung der Eingaben ist nicht beschränkt auf eine Schwellenfunktion, sondern kann auch teilweise linear, eine Gaußsche Funktion oder sigmoid (S-Funktion) sein, wobei letztere laut JAIN ET AL. [JMM96] die bei Weitem meistbenutzte in KNNs ist. McCulloch und Pitts bewiesen mithilfe dieses Modells, dass eine synchrone Anordnung der Neurone in einem Netz mit wohlgewählten gewichteten Eingangssignalen allgemeine Berechnungen lösen können. [Kro08; MP43; JMM96; SKP97]

Der Hauptvorteil neuronaler Netze liegt in der Verarbeitung *a priori* unbekannter Informationen, die in Datenmengen versteckt sind. Mithilfe des gezielten Anpassens der Gewichtungskoeffizienten werden gezielte Ausgaben erzeugt und somit bestimmte Bedingungen erfüllt. Diese Größen und Abläufe bilden so die Grundlage des Lernens neuronaler Netze, eine fundamentale Eigenschaft der Intelligenz, welche im vorherigen Abschnitt bereits erklärt wurde. Ein Anwendungsbeispiel des überwachten Lernens bildet das "feed forward" oder vorwärtsgerichtete NN, welches eine Kategorie von KNNs bezüglich ihrer Architektur darstellt (Abb 3.2). [SKP97]




Abb. 3.2.: Allgemeiner Aufbau eines vorwärtsgerichteten KNN-Modells

Hierbei sieht man die bereits vorgestellten Neurone in Verbindung durch Schichten, wobei die Eingaben x_1, x_2, \dots, x_n die Eingabeschicht, $a_1, a_2, a_3, \dots, a_n$ die verborgene Schicht und schließlich y_1 und y_2 die Ausgabeschicht bilden. Dabei sind die Eingabe- und Ausgabeschicht in der Regel jeweils ein Mal vertreten, jedoch können mehrere verborgene Schichten vorkommen. Wenn das der Fall ist, spricht man von einem "tiefen" neuronalen Netz. Diese Netze sind namensgebend für ihre Anwendung im tiefen Lernen (Deep Learning) [Kro08]. Bei der obigen Abbildung handelt es sich um ein zweischichtiges NN, weil die Eingabeschicht keine Berechnungen durchführt und somit nicht gezählt wird. Vorwärtsgerichtet ist es, weil die Kommunikation zwischen den Neuronenschichten

nur zur jeweils folgenden Schicht geschieht. Als Pendant dazu ist das "recurrent/feedbacköder rückgekoppelte NN zu erwähnen, bei welchem die Neuronen mit sich selbst (direkte Rückkopplung), mit einem Neuron einer vorherigen Schicht (indirekte Rückkopplung) oder mit Neuronen derselben Schicht (laterale Rückkopplung) kommunizieren können.

Recurrent/Feedback NN

- Recurrent NN (Verarbeitung Sequenzieller Daten, Sprachverarbeitung, NaturalLanguageProcessing NLP)

GAN

- GAN

SAGAN

NoGAN

Convolutional NN

- CNN's erklären, Schichten und Aufgaben [AMA17]

3.1.3. Tiefes Lernen

- DeepLearning [LBH15] [SS18]

4. Verwandte Arbeiten

- Zhang, Isola, Efros: 2016 Colorful Image Colorization (using CNN) - weniger Abhängigkeit von Nutzerinteraktion - class-rebalancing at training time, um Farbendiversität zu erhöhen - feed-forward pass in a CNN trainiert an über 1 Million Bildern - Evaluation mittels "Colorization Turing Test", 32% Erfolg, die Befragten zu foolen - Colorization acting as Cross-channel encoder

4.1. Neuronale Netze GAN's: Fokus auf DeOldify

4.1.1. Deep Learning Techniken des Kolorierens

4.1.2. DeOldify

4.2. Implementierung

4.3. Evaluation (Vergleich Projekte)

4.4. Fazit und Ausblick

4.5. Literaturverzeichnis

Literatur

- [Lef07] Wolfgang Lefèvre. „Inside the camera obscura–Optics and art under the spell of the projected image“. In: (2007).
- [Mil98] Allan A Mills. „Vermeer and the camera obscura: Some practical considerations“. In: *Leonardo* 31.3 (1998), S. 213–218.
- [Ede84] Josef Maria Eder. *Ausführliches handbuch der photographie*. Bd. 1. W. Knapp, 1884.
- [BW00] M Susan Barger und William B White. *The Daguerreotype: nineteenth-century technology and modern science*. JHU Press, 2000.
- [Lav+09] Bertrand Lavédrine et al. *Photographs of the past: process and preservation*. Getty Publications, 2009.
- [Hac12] Juliet Hacking. *Foto: Fotografie; die ganze Geschichte*. DuMont-Verlag, 2012.
- [Lua+07] Qing Luan et al. „Natural image colorization“. In: *Proceedings of the 18th Eurographics conference on Rendering Techniques*. 2007, S. 309–320.
- [Han13] John Hannavy. *Encyclopedia of nineteenth-century photography*. Routledge, 2013.
- [HH96] Heinz K Henisch und Bridget Ann Henisch. *The painted photograph, 1839-1914: origins, techniques, aspirations*. Penn State University Press, 1996, S. 21.
- [Fer08] S Ferguson. „In living color: Process and materials of the hand-colored daguerreotype“. In: *The Daguerreian Annual* (2008), S. 13–18.
- [Tow73] John Towler. *The Silver Sunbeam: A Practical and Theoretical Text-book on Sun Drawing and Photographic Printing*. E. & HT Anthony, 1873.
- [II05] Michael Ivankovich und Susan Ivankovich. *Early Twentieth Century Hand-painted Photography: Identification & Values*. Collector Books, 2005.
- [Hop10] Jonathan Hoppe. „Spectroscopic analysis of hand-colored photographs and photographic hand-coloring materials“. Diss. University of Delaware, 2010.
- [Fak+13] Rasool Fakoor et al. „Using deep learning to enhance cancer diagnosis and classification“. In: *Proceedings of the international conference on machine learning*. Bd. 28. ACM, New York, USA. 2013, S. 3937–3949.
- [Rot+15] Holger R Roth et al. „Improving computer-aided detection using convolutional neural networks and random view aggregation“. In: *IEEE transactions on medical imaging* 35.5 (2015), S. 1170–1181.
- [LBH15] Yann LeCun, Yoshua Bengio und Geoffrey Hinton. „Deep learning“. In: *nature* 521.7553 (2015), S. 436–444.
- [DFO20] Marc Peter Deisenroth, A Aldo Faisal und Cheng Soon Ong. *Mathematics for machine learning*. Cambridge University Press, 2020.
- [MKB16] Mohssen Mohammed, Muhammad Badruddin Khan und Eihab Bashier Mohammed Bashier. *Machine learning: algorithms and applications*. Crc Press, 2016.
- [SB14] Shai Shalev-Shwartz und Shai Ben-David. *Understanding machine learning: From theory to algorithms*. Cambridge university press, 2014.

- [MM21] John Paul Mueller und Luca Massaron. *Machine learning for dummies*. John Wiley & Sons, 2021.
- [Goo+20] Ian Goodfellow et al. „Generative adversarial networks“. In: *Communications of the ACM* 63.11 (2020), S. 139–144.
- [Sem22] Kilian Semmelmann. *Der Clustering Guide: Definition, Methoden und Beispiele*. Kobold AI, 2022.
- [Kro08] Anders Krogh. „What are artificial neural networks?“ In: *Nature biotechnology* 26.2 (2008), S. 195–197.
- [JMM96] Anil K Jain, Jianchang Mao und K Moidin Mohiuddin. „Artificial neural networks: A tutorial“. In: *Computer* 29.3 (1996), S. 31–44.
- [MP43] Warren S McCulloch und Walter Pitts. „A logical calculus of the ideas immanent in nervous activity“. In: *The bulletin of mathematical biophysics* 5.4 (1943), S. 115–133.
- [SKP97] Daniel Svozil, Vladimir Kvasnicka und Jiri Pospichal. „Introduction to multi-layer feed-forward neural networks“. In: *Chemometrics and intelligent laboratory systems* 39.1 (1997), S. 43–62.
- [AMA17] Saad Albawi, Tareq Abed Mohammed und Saad Al-Zawi. „Understanding of a convolutional neural network“. In: *2017 international conference on engineering and technology (ICET)*. Ieee. 2017, S. 1–6.
- [SS18] Pramila P Shinde und Seema Shah. „A review of machine learning and deep learning applications“. In: *2018 Fourth international conference on computing communication control and automation (ICCUBEA)*. IEEE. 2018, S. 1–6.

4.1. Anhang